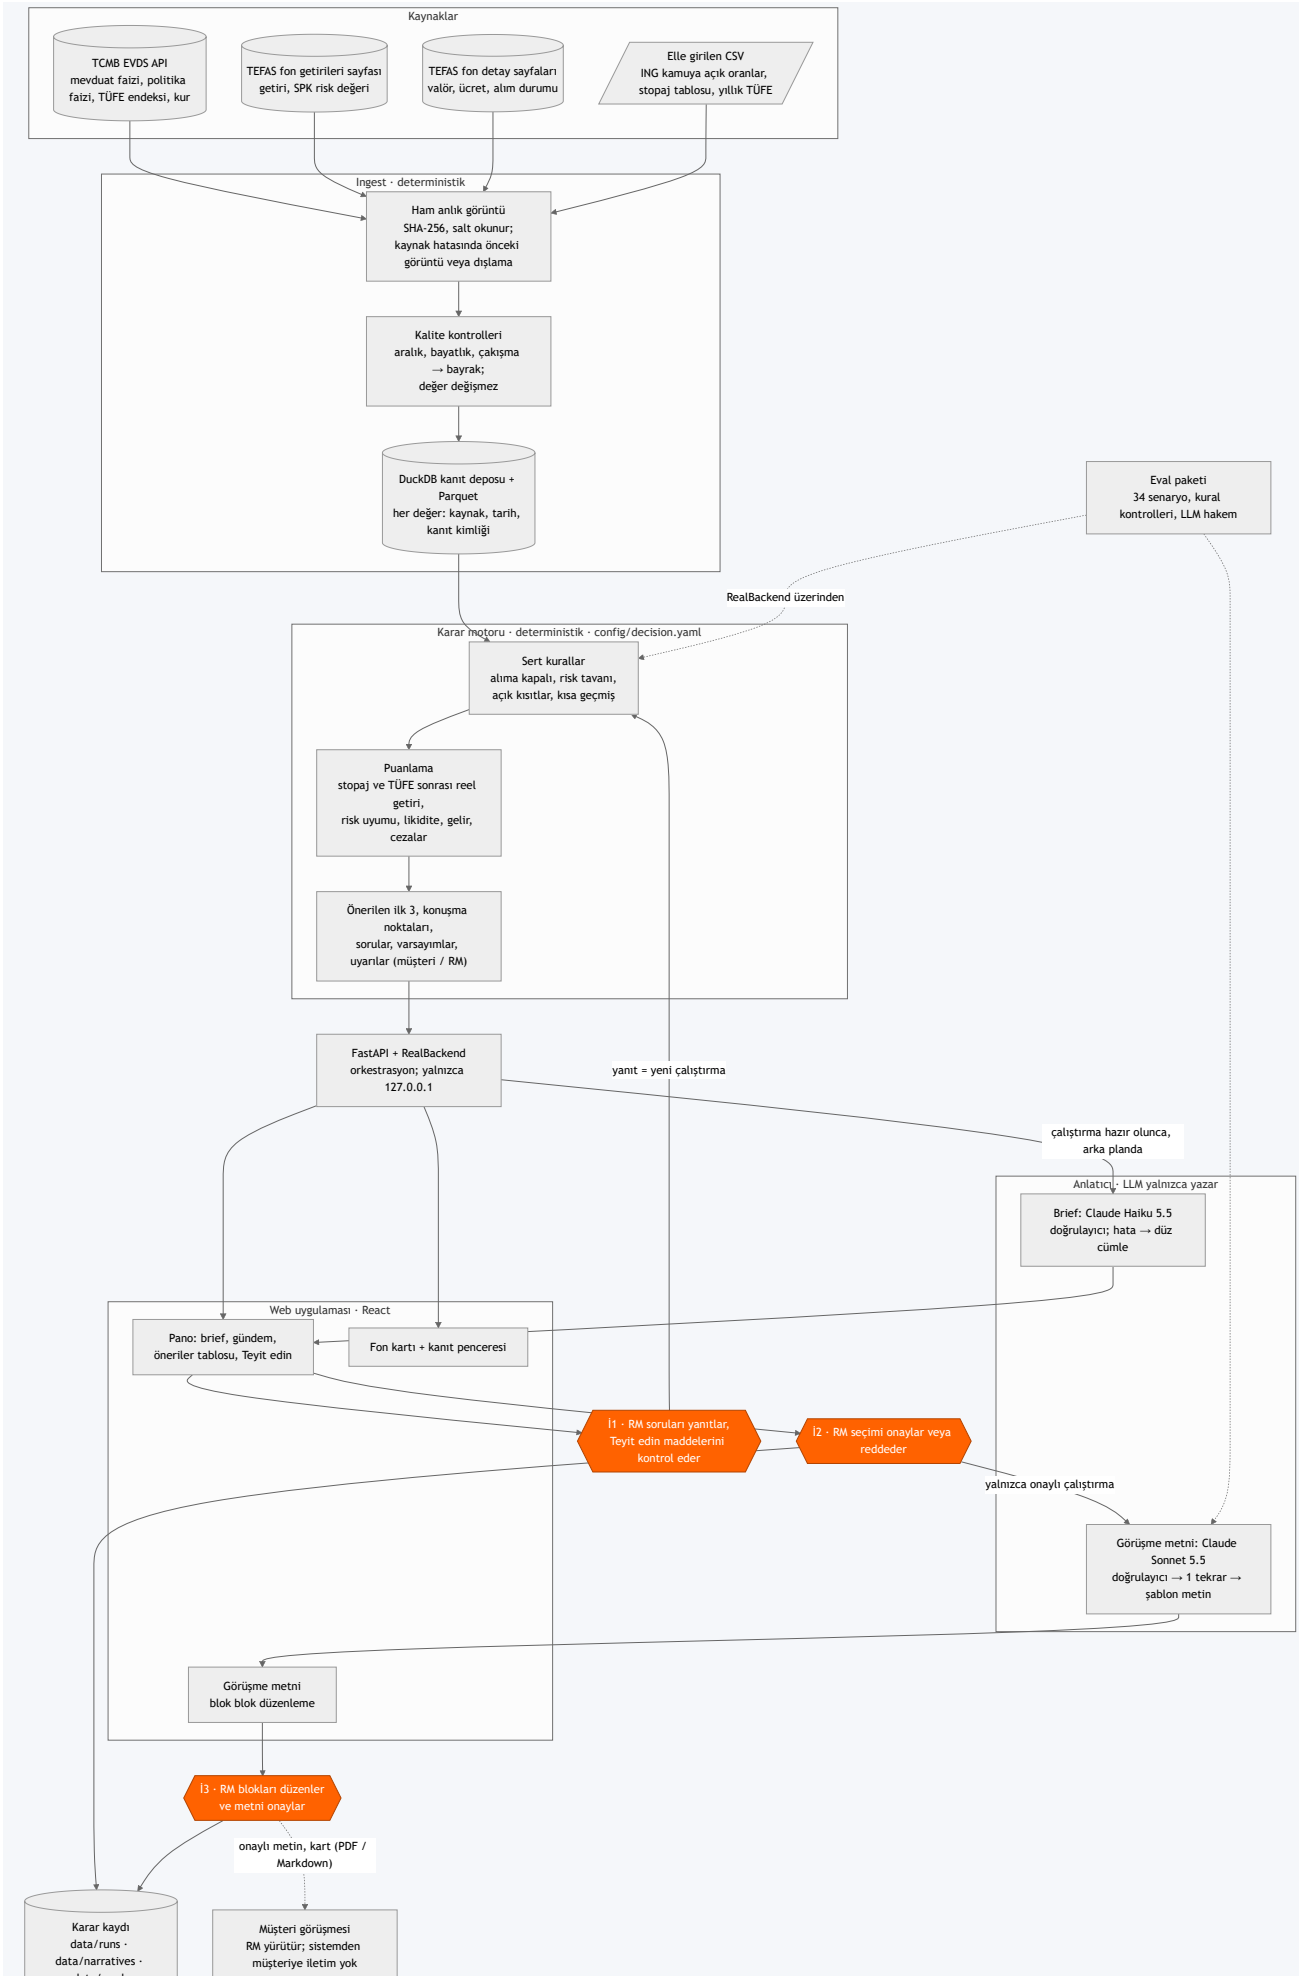
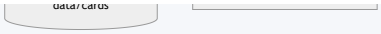
Çözüm tasarımı

> Teslimat 4 · Taslak (2026-10-12) · Ölçümler: değerlendirme raporu `data/eval/20261012-201431-full` (dondurulmuş anlık görüntü `20261010-183835-6813`) ve maliyet defteri `data/narratives/costs.jsonl`. **[VARSAYIM]** ile işaretli noktalar mentorlarla teyit edilecek.

1. Mimari özeti

Sistem dört katmandan oluşur: veri toplama (ingest), deterministik karar motoru, dil üreten anlatıcı (narrator) ve RM'in çalıştığı yerel web uygulaması. Kararı kod verir, metni LLM yazar, metni yine kod denetler, son sözü RM söyler. Turuncu altıgenler insan onay noktalarıdır.


Kaynaklar
TCMB EVDS API
mevduat faizi, politika faizi, TÜFE endeksi, kur
TEFAS fon getirileri sayfası
getiri, SPK risk değeri
TEFAS fon detay sayfaları
valör, ücret, alım durumu
Elle girilen CSV
ING kamuya açık oranlar, stopaj tablosu, yıllık TÜFE
Ingest · deterministik
Ham anlık görüntü
SHA-256, salt okunur; kaynak hatasında önceki görüntü veya dışlama
Kalite kontrolleri
aralık, bayatlık, çakışma → bayrak; değer değişmez
DuckDB kanıt deposu + Parquet
her değer: kaynak, tarih, kanıt kimliği
Eval paketi
34 senaryo, kural kontrolleri, LLM hakem
RealBackend üzerinden
Karar motoru · deterministik · config/decision.yaml
Sert kurallar
alıma kapalı, risk tavanı, açık kısıtlar, kısa geçmiş
Puanlama
stopaj ve TÜFE sonrası reel getiri, risk uyumu, likidite, gelir, cezalar
Önerilen ilk 3, konuşma noktaları, sorular, varsayımlar, uyarılar (müşteri / RM)
FastAPI + RealBackend
orkestrasyon; yalnızca 127.0.0.1
yanıt = yeni çalıştırma
çalıştırma hazır olunca, arka planda
Anlatıcı · LLM yalnızca yazar
Brief: Claude Haiku 5.5
doğrulayıcı; hata → düz cümle
Web uygulaması · React
Pano: brief, gündem, öneriler tablosu, Teyit edin
Fon kartı + kanıt penceresi
İ1 · RM soruları yanıtlar, Teyit edin maddelerini kontrol eder
İ2 · RM seçimi onaylar veya reddeder
yalnızca onaylı çalıştırma
Görüşme metni: Claude Sonnet 5.5
doğrulayıcı → 1 tekrar → şablon metin
Görüşme metni
blok blok düzenleme
İ3 · RM blokları düzenler ve metni onaylar
onaylı metin, kart (PDF / Markdown)
Karar kaydı
data/runs · data/narratives ·
Müşteri görüşmesi
RM yürütür; sistemden müşteriye iletim yok



Ingest yalnızca robots.txt'nin izin verdiği HTML sayfalarını okur (TEFAS `/api/` yolu yapılandırmada reddedilir). ING oranları ve stopaj oranları, kaynak adresi ve tarihiyle birlikte elle girilir; kodda vergi oranı yoktur.

2. Bileşenler

Bileşen	Sorumluluk	Teknoloji	Tür	Dosya / modül
Kaynak adaptörleri	EVDS, TEFAS sayfaları, elle CSV; bozuk satırı nedeniyle kaydeder	Python, httpx, openpyxl	Deterministik	`src/rmprep/ingest/adapters/`
Anlık görüntü	Ham veriyi değişmez ve özetli (SHA-256) saklar	Dosya sistemi	Deterministik	`ingest/snapshot.py`
Kalite kontrolleri	Aralık dışı, bayat, çakışan, yinelenen değerlere bayrak	Saf fonksiyonlar	Deterministik	`ingest/quality.py`
Kanıt deposu	Her değeri kimliğiyle saklar, Parquet'e aktarır	DuckDB	Deterministik	`ingest/store.py`, `ingest/pipeline.py`
Karar motoru	Evren, sert kurallar, puan, güven ve kararlılık, önerilen 3, sorular, uyarılar	Python, YAML	Deterministik	`src/rmprep/decision/`, `config/decision.yaml`
Gruplama	Kısa liste grupları ve önerilen ilk 3'ün tek kuralı	Python	Deterministik	`src/rmprep/grouping.py`
Orkestrasyon	Çalıştırma, onay, arka plan işleri (2 iş parçacığı), kayıt	Python	Deterministik	`src/rmprep/backend.py`
JSON API	Görünüm modelleri (sıra, yıldız, uygunluk halkası); iş kuralı eklemez	FastAPI, uvicorn	Deterministik	`src/rmprep/api/`
Web uygulaması	Pano, fon kartı, kanıt penceresi, görüşme metni, yazdırma	React, TypeScript, Tailwind, Vite	Arayüz + insan kararı	`web/`
Brief	Pano için RM'e 1–2 cümle	Claude Haiku 5.5	LLM + kod denetimi	`narrator/brief.py`, `rmprep/brief.py`
Görüşme metni	8 bölümlü hazırlık metni ve konuşma metni	Claude Sonnet 5.5	LLM + kod denetimi	`narrator/` (`facts`, `prompt`, `llm`, `validator`, `template`, `service`)
Blok düzenleme kontrolü	RM'in değiştirdiği bloğu yeniden denetler	Python	Deterministik	`src/rmprep/edits.py`, `narrator/blocks.py`
Eval paketi	Senaryolar, kural kontrolleri, rapor; dil kalitesi için hakem	Python + Claude Haiku 5.5	Deterministik + LLM hakem	`src/rmprep/eval/`, `config/eval.yaml`

3. LLM'in rolü ve sınırları

LLM hiçbir ürünü seçmez, elemez veya puanlamaz; yalnızca karar motorunun çıktısını Türkçe (veya İngilizce) metne çevirir.

- **Girdi: olgu paketi (kod).** Persona bağlamı, RM'in onayladığı seçim, her seçeneğin gerekçeleri ve kanıt kimlikli sayıları, grup alternatifleri, yalnızca müşteriye yönelik uyarılar, varsayımlar ve sorular. Elenen ürünler adla girmez; RM'e özel uyarılar pakete hiç girmez.
- **Çıktı: yapılandırılmış JSON.** API'nin `json_schema` biçimi kullanılır. Her cümle seçenek ve kanıt kimliklerini taşır; her öneri için müşteri önceliklerinden 1–3 ihtiyaç etiketi gelir.
- **Doğrulayıcı (kod).** Metin şu durumlarda reddedilir:
- olgu paketinde olmayan bir sayı veya tarih; iç değer (puan, sayım, bayrak adı);
- izin verilmeyen bir seçenek adı (elenen veya listede olmayan ürün; ekrandaki kısa adlar da yakalanır);
- yasak ifade ("garanti", "risksiz", "kesin getiri" vb.; fon adları taramadan önce çıkarılır, "GARANTİ PORTFÖY" bu yüzden hata sayılmaz);
- kaynaksız cümle veya var olmayan kimlik (konuşma noktaları, öneriler, alternatifler, dikkat);
- ING ürün adının yanında ING'ye ait olmayan bir oran (etiket kuralı);
- müşteri önceliği olmayan ihtiyaç etiketi, eksik bölüm, eksik varsayım, eksik "yatırım tavsiyesi değildir" cümlesi.
- **Hata yolu.** Bulgularla bir kez yeniden denenir; ikinci hatada olgu paketinden kurulan şablon metin ve "Otomatik metin doğrulanamadı" bandı gösterilir. Brief için tekrar yoktur; hata veya API sorununda personanın düz cümlesi kalır.
- **Önbellek ve maliyet.** Metin (çalıştırma, dil, istem sürümü, model) anahtarıyla diske yazılır; aynı çalıştırma ikinci çağrı yapmaz. Sistem istemi önbelleğe alınır. Günlük sınır **5 ABD doları**dır; aşılırsa şablon metin gelir. Her çağrı maliyet defterine yazılır.

Çıktı	Model	Ölçülen maliyet	Ölçülen süre
Görüşme metni	Claude Sonnet 5.5 (`claude-sonnet-5-5` , effort medium)	yeni metin başına ortalama **0,042 $** (eval, 25 metin); hız testinde 0,049 $	ortalama 27 sn (en çok 45 sn)
Pano brief'i	Claude Haiku 5.5 (`claude-haiku-5-5`)	49 çağrıda ortanca **0,0008 $** (0,0003–0,0013 $)	arka planda
Eval hakemi	Claude Haiku 5.5	tam pakette 0,008 $	—

Tasarım belgesindeki brief tahmini (yaklaşık 0,003 $) ölçülen değerin üstündedir; tabloda ölçülen değer kullanılmıştır.

4. İnsan onay noktaları

#	RM kontrolü	Sistemin zorladığı kural
1	Belirsiz risk profili veya tanınmayan kısıt metnini yanıtlar	Engelleyici soru açıkken sıralama yapılmaz (`needs_rm_input`); yanıt yeni bir çalıştırmadır
2	"Teyit edin" maddelerini (ör. yatırım tutarı dilimi) müşteriyle kontrol eder	Motor eksik değeri sessizce tahmin etmez; güvenli düzeyi seçer ve varsayım olarak yazar. Liste onayı engellemez, açık madde sayısını hatırlatır
3	Bir kaynağı dışlar veya personayı düzenler	Dışlanan kaynak notlarda görünür. Düzenlenmiş persona **test çalıştırmasıdır** ve onaylanamaz (arka uç reddeder)
4	Açık kısıtı gerekçeyle kaldırır (P02 döviz sınırı)	Kaldırma yalnızca RM yanıtıyla olur ve varsayım olarak kayda geçer

#	RM kontrolü	Sistemin zorladığı kural
5	Önerilen ilk 3'ten seçimi yapar, not ekler, onaylar veya reddeder	Ret not ister. Görüşme metni yalnızca onaylı çalıştırma için üretilir
6	Metni blok blok düzenler; "Orijinale dön" ile geri alır	Her blok yeniden denetlenir. Yasak ifade, izin dışı seçenek, iç bilgi ve ING etiket bulguları onayı **engeller**; olgu dışı sayı yalnızca uyarır
7	"Metni onayla"	Engelleyici bulgu açıkken onay reddedilir; onaydan sonra düzenleme kapanır. Kart ve PDF onaylı metni kullanır
8	"RM notu · yalnızca sizin için" bölümünü okur	RM'e özel uyarılar (ör. ING oranı ile piyasa farkı) olgu paketine girmez, müşteri metninde yer almaz

Sistemin müşteriye bir iletim kanalı yoktur: uygulama yerel çalışır ve çıktıyı yalnızca RM görür. Karar kaydı şunları tutar: çalıştırma kimliği, yapılandırma özeti, anlık görüntü, dışlanan kaynaklar, kullanılan persona, RM durumu, seçim ve notlar (`data/runs/`); onaylı metin, model, istem sürümü, doğrulayıcı sonucu ve maliyet (`data/narratives/`).

5. Güvenilirlik

- **Kaynak hatası.** Her kaynak için yapılandırmada `on_failure` vardır: önceki anlık görüntüye dönülür (satırlar `fallback_snapshot` bayrağı taşır) veya kaynak dışlanır. RM de bir kaynağı ekrandan dışlayabilir; yalnızca o kaynaktan doğan çakışmalar kaybolur.
- **Tekrar ve belirlilik.** Anlık görüntüden sonraki her adım saf fonksiyondur: `rmprep replay <id>` ağa çıkmadan aynı Parquet dosyasını bayt bayt üretir. Karar motoru saat ve rastgelelik kullanmaz; aynı girdi aynı `run_id`'yi ve aynı sonucu verir. Metin önbellekten aynen gelir (eval: 5/5 tekrar senaryosu).
- **İzlenebilirlik.** Her sayı bir kanıt kimliğine bağlıdır; ekrandaki "K" işareti değeri, kaynağı, tarihi ve bayrakları açar. Eval'de "her seçenek ve her cümle kanıt gösterir" kontrolü 39/39 çalıştırmada geçti.
- **Kalıcılık.** Onaylı ve reddedilmiş çalıştırmalar, blok düzenlemeleri ve onaylı metinler diske yazılır; sunucu yeniden başlarsa aynı girdi aynı kimliği verir ve kayıt geri yüklenir.
- **Testler.** `pytest` 1.636 test toplar; hiçbir test ağa çıkmaz (LLM testleri sahte istemciyle çalışır). Web uygulamasının ayrıca Vitest testleri vardır.
- **Eval paketi.** 34 senaryo, 39 çalıştırma: temel personalar, jüri tarzı persona ve kısıt değişiklikleri, kaynak dışlama, bozuk veri ve 13 regresyon senaryosu. Kural kontrolleri %100, doğrulayıcı geçiş oranı %100 (25/25 LLM metni, şablona düşüş yok), yasak ifade 0. Hakemin dil puanları daha düşüktür ("müşteriye uyarlanmış" %57, "RM için açık" %50); bu alan iyileştirme konusudur (bkz. Teslimat 5).

6. Neden bu tasarım?

1. **Deterministik çekirdek.** Uygunluk, eleme ve sıralama denetlenebilir, test edilebilir ve tekrar üretilebilir olmalıdır. SPK yerindelik kuralı ve "kısıt ihlali sıfır" hedefi olasılıklı bir modele bırakılamaz. Tüm ağırlıklar, eşikler ve metin kalıpları `config/decision.yaml` içindedir; ayar bir yapılandırma değişikliğidir ve yapılandırma özeti kayda girer.
2. **LLM yalnızca dilin gerektiği yerde.** Müşteriye uyarlanmış, akıcı bir metin kuralla iyi yazılamaz; LLM'in katkısı buradadır. Kod olgu paketini sınırlar ve çıktıyı denetler; bu yüzden bir LLM hatası yanlış bir öneriye dönüşemez, en kötü durumda şablon metne düşer.
3. **Çalışma anında çoklu ajan döngüsü yok.** Her metin tek çağrıdır (en çok bir tekrar). Bu yapı maliyeti (metin başına yaklaşık 0,05 $), süreyi ve davranışı öngörülebilir kılar; araç seçen bir ajan

döngüsü bu işte doğruluk eklemez, denetimi zorlaştırır. Ajan sayısı bir hedef değildir.
4. **Yerel web uygulaması.** Sunucu yalnızca `127.0.0.1` adresine bağlanır; müşteriye iletim ve otomatik işlem yoktur. Arayüz RM'in onay adımlarını görünür kılar.

Geliştirme süreci (çalışma zamanı değil). Sistem bir lider ve modül başına bir işçi Claude Code oturumuyla, ayrı git çalışma ağaçlarında geliştirildi. Sözleşmeler (`contracts.py`) lider tarafından donduruldu; her adım yeşil `pytest` ile kapandı (`docs/workflow.md`). Bu çoklu ajan yapısı yalnızca yapım içindir; ürün çalışırken kullanılmaz.

Ödünleşimler.

- Veri kamuya açık kaynaklardan ve elle girilen satırlardan gelir; TEFAS değerleri "kontrol gerekli" bayrağı taşır, güven puanı bunu yansıtır.
- Kural tabloları ve risk bantları uzman görüşüyle değil, ilk değerlerle kuruldu **[VARSAYIM]**.
- Persona metni yalnızca tam eşleşmeyle okunur; tanınmayan ifade soru olur. Bu güvenlidir ama RM'e ek iş çıkarır.
- Çalıştırmalar bellekte tutulur; yalnızca onaylanmış veya reddedilmiş çalıştırmalar diske yazılır.

Üretimde değiştireceklerimiz.

- Banka sistemleri: müşteri portföyü ve tutarı, gerçek ürün raf listesi, ING oranlarının ve stopaj tablosunun resmî akışla gelmesi.
- Kimlik doğrulama, rol yetkisi ve kayıtların merkezi, değiştirilemez bir denetim deposuna yazılması.
- KAP bildirimleri: KAP otomatik erişimi engellediği için prototipte yoktur; lisanslı bir veri akışıyla eklenmelidir **[VARSAYIM]**.
- Müşteri verisi bankadan çıkmadan önce KVKK değerlendirmesi ve banka onaylı bir model ortamı.
