Test ve öğrenimler

> Teslimat 5 · Taslak (2026-10-12) · Sayılar: son tam değerlendirme `data/eval/20261012-201431-full` (dondurulmuş veri anlık görüntüsü `20261010-183835-6813`, karar yapılandırması `2534f798cc47`, anlatıcı `claude-sonnet-5-5` istem `n6`, hakem `claude-haiku-5-5`) ve önceki tam değerlendirme raporları. **[VARSAYIM]** ile işaretli değerler ölçülmedi.

1. Test yaklaşımı

Çözümü üç katmanda test ettik. Her katman farklı bir soruya cevap verir.

Katman	Ne test eder	Nasıl
Birim ve sözleşme testleri	Her modülün kuralı tek başına doğru mu? (veri alma, karar motoru, anlatıcı doğrulayıcısı, API)	`pytest`, 83 dosyada **1.636** test, başarısız test yok (2026-10-12); ağ erişimi yok, LLM yerine sahte model
Senaryo değerlendirme paketi	Sistem uçtan uca, jürinin değiştirebileceği girdilerle doğru davranıyor mu?	34 senaryo, 39 çalıştırma; dondurulmuş anlık görüntü; tek komut `python -m rmprep eval`
Ekranda elle inceleme	RM için kullanışlı mı?	Kullanıcı ile demo ve ekran incelemesi (2026-10-11 geri bildirimi web arayüzünün yeniden tasarımına yol açtı)

Değerlendirme paketi her senaryoyu gerçek arka uçtan geçirir: karar, sabit bir seçimin onayı, görüşme metni. Kontroller üç türdür:

1. **Deterministik kurallar (kod):** kısıt uyumu, risk tavanı, kaynak atfı, uydurma veri, tekrar tutarlılığı. Hedef %100.
2. **LLM metninin doğrulayıcısı (kod):** metindeki her sayı olgu paketinde mi, yalnızca izinli ürünler mi adlandırılıyor, yasaklı ifade var mı, her cümle kanıt kimliği gösteriyor mu.
3. **LLM hakemi (Claude Haiku 5.5):** yalnızca kodun ölçemediği şeyler: metin bu müşteriye mi uyarlanmış, RM için açık mı, dengeli mi. Kural kontrolleri hakeme bırakılmaz.

Veri dondurulduğu için bir sonuç değişirse kod veya yapılandırma değişmiştir. Metinler önbellekte tutulur; aynı girdi aynı metni verir.

Neden bu başarı göstergeleri?

Göstergeleri brifin §9.1 sorularından ve §12 kurallarından türettik:

Brif sorusu	Göstergemiz	Neden
Müşteri kısıtlarına uyum	Kural 5 kontrolü, risk tavanı, açık kısıtlar sert kural (D13), alıma kapalı fon yok (D12)	Jüri her senaryoda kural 5'i kontrol ediyor; tek ihlal güveni bozar
Eksik / çelişkili veri	Eksik veri gösteriliyor, hatalı veri işaretleniyor, tahmin yerine soru	SPK yerindelik kuralı eksik bilgiyle tavsiyeye izin vermez

Brif sorusu	Göstergemiz	Neden
Kaynakların doğru kullanımı	Her seçenek ve her cümle kanıt kimliği gösteriyor (kural 2); uydurma sayı yok (kural 3)	LLM metninin en büyük riski uydurma sayı
Tekrar tutarlılığı	Aynı girdi → aynı `run_id`, aynı sonuç, aynı metin	RM ve denetçi aynı sonucu yeniden üretebilmeli
Önerilerin tutarlılığı ve uyarlama	Persona değişikliği sonucu beklenen yönde değiştiriyor; çeşitli öneri (D19); hakem "uyarlanmış" puanı	Herkese aynı ürünü öneren bir araç RM'e katkı sağlamaz
İşlem süresi ve maliyet	Saniye ve USD (yalnızca raporlanır)	Hazırlık süresine sığmalı; bütçe sınırı $5 / paket

2. Başarı göstergeleri ve hedefler (son ölçüm)

Gösterge	Değer	Hedef	Karşılandı
Kural kontrolleri geçme oranı	%100 (218 geçti, 0 kaldı)	%100	evet
Anlatıcı doğrulayıcı geçme oranı (LLM, şablona düşmeden)	%100 (25 / 25)	≥ %95	evet
Yasaklı ifade (kural 6)	0	0	evet
Kural 5: reddedilen / kısıtı ihlal eden seçenek listede, seçimde veya metinde	37 / 37 geçti	%100	evet
Risk tavanının üstünde seçenek yok	37 / 37	%100	evet
Açık kısıtlar sert kural (D13)	12 / 12	%100	evet
Uydurma veri yok (kural 3)	39 / 39	%100	evet
Kaynak atfı (kural 2)	39 / 39	%100	evet
Eksik veri gösteriliyor	7 / 7	%100	evet
Hatalı veri işaretleniyor, kullanılmıyor	3 / 3	%100	evet
Tahmin yerine soru	2 / 2	%100	evet
Tekrar tutarlılığı	5 / 5	%100	evet
Persona değişikliği beklenen yönde	21 / 21	senaryo başına	evet
Çeşitli öneri (D19)	20 / 20	%100	evet
Kanıt toplama / karar süresi (çalıştırma başına ort.)	0,42 sn / 1,16 sn (en çok 5,32 / 1,92 sn)	yalnızca rapor	—
Görüşme metni süresi	ort. 27,39 sn (en çok 45,25 sn)	yalnızca rapor	—
Maliyet	metin başına $0,042; paket $1,05 (sınır $5)	yalnızca rapor	—
Hakem: uyarlanmış / RM için açık / dengeli	%57 / %50 / %50	yalnızca rapor	—

Bir kontrol yalnızca ilgili senaryoda çalışır; uygulanmayanlar oranlara girmez.

3. Senaryo grupları

Grup	Sayı	Neyi değiştirir	Örnek
Temel	5 (her biri 2 kez)	Hiçbir şey; P01–P05 olduğu gibi	`base-p01` … `base-p05`
Hatalı / çelişkili veri	3	Kanıta hata enjekte eder	kaynaklar arası çelişen risk değeri, aralık dışı risk, eskimiş getiri
Persona değişikliği (Jüri Challenge tarzı)	5	Bir müşteri alanını değiştirir	P03 "Agresif" → "Muhafazakâr"; P03 vade "1 yıl"; P04 likidite "Yüksek"; P01 döviz tercihi bilinmeyen metin; P05 "Dengeli"
Kısıt	4	Açık kısıt ekler	"döviz maruziyeti istemiyor", "yüksek riskli ürün istemiyor"; bilinmeyen kısıt metni → RM'e soru
Veri erişimi	4	Bir kaynağı dışlar	TEFAS detay yok; elle girilen veri yok (mevduat oranı, TÜFE, stopaj); TEFAS web yok
Regresyon	13	Geçmiş hataları sabitler	hata analizi vakaları 1–8 (bölüm 4 ve 5)

Örnek: TEFAS web dışlanınca P01'de 2 seçenek kalır, fon önerilmez; bilinmeyen kısıtta sonuç `needs_rm_input` olur.

4. Hata analizi: herkese aynı öneri (vaka 8, karar D19)

Bulgu (2026-10-12). Dondurulmuş anlık görüntüde 5 personanın 4'ü ilk üç öneri olarak yalnızca nakit benzeri, SPK risk 1 fonlar aldı. İki çift tamamen aynı listeyi aldı (P01 = P04: Nurol Para Piyasası, İstanbul KV Borçlanma, Ak Para Piyasası Katılım; P02 = P05: One Portföy Para Piyasası ile aynı iki fon); İstanbul KV Borçlanma ve Ak Para Piyasası Katılım dördünde de vardı. Bu grupta Muhafazakâr P01'in yanında Dengeli P02 ve P04 (risk tavanı 5) ile Temkinli P05 de vardı. Tüm kural kontrolleri bu sırada %100 geçiyordu: hiçbir kısıt ihlal edilmemişti, ama öneri müşteriye uyarlanmamıştı. Bu, "kurallara uyum" ile "iyi öneri" arasındaki farkı gösterdi.

Kök nedenler.

1. **Geçmiş getirinin baskınlığı.** Son bir yılda TL nakit benzeri fonlar en iyi reel getiriyi verdi (TÜFE ve stopaj sonrası +%7–9); dengeli fonlar +%3, hisse ≈ %0, altın −%13.
2. **Risk bütçesini kullanan bir ölçüt yoktu.** `low_risk` ölçütü Dengeli müşteride de düşük riski ödüllendiriyordu; anapara cezası risk 5 fonları ayrıca vuruyordu (P04: risk 5 karma fon 0,02 puan, para piyasası 0,91).
3. **Çeşitlilik yanlış düzeyde ölçülüyordu.** Çeşitlilik `fund_kind` üzerinden çalışıyordu; para piyasası, kısa vadeli borçlanma ve katılım para piyasası farklı tür ama aynı varlık sınıfı (kısa vadeli TL nakit).

Eksik SPK risk değerleri neden değildi (her türde fonların %3–10'u).

Düzeltme (D19, kullanıcı onayı 2026-10-12).

Değişiklik	İçerik
Varlık sınıfı	Her seçeneğe `asset_class`: `nakit_benzeri`, `borclanma`, `dengeli`, `hisse`, `altin_doviz` (tür ve ad kurallarıyla)
Risk uyumu bandı	`low_risk` yerine `risk_fit`: Muhafazakâr [1, 2], Temkinli [2, 3], Dengeli [3, 5], Agresif [4, 7]; bandın altındaki her seviye için ceza

Değişiklik	İçerik
Sınıf kuralı	Dengeli / Agresif müşteride veya çeşitlendirme önceliğinde: sınıf başına en çok 1, en çok 1 nakit benzeri öneri
Reel getiri tabanı (D19b)	Sınıf kuralı negatif 1 yıllık reel getirili bir fonu öne çıkaramaz

Ayar. İlk denemede `per_step` 0,25 idi; Dengeli personaların önerileri risk 2'de kaldı. `per_step` 0,5 ve `risk_fit` ağırlığı 2,0 ile öneriler bandın içine girdi. Bantlar bir **[VARSAYIM]**; mentorlarla teyit edilecek.

Sonuç (ölçüldü).

Persona	D19 öncesi	D19 sonrası (sınıf, risk, 1 yıllık reel getiri %)
P01 Muhafazakâr	3 nakit benzeri, risk 1	değişmedi (kural uygulanmaz; doğru davranış)
P02 Dengeli	aynı 3 nakit benzeri, risk 1	nakit r2 +8,0 · borçlanma r2 +8,4 · dengeli r3 +12,8
P04 Dengeli	aynı 3 nakit benzeri, risk 1	borçlanma r3 +5,9 · nakit r2 +6,7 · dengeli r3 +3,3
P05 Temkinli	aynı 3 nakit benzeri, risk 1	3 nakit benzeri, risk 2 (kendi bandı)
P03 Agresif	farklı	dengeli r6 · hisse r7 · katılım fonu r5 +26,3

D19 sonrası **hiçbir iki temel persona aynı ilk üçü paylaşmıyor**. Raporun satırı "1 of 5 base personas share the same recommended top 3" şunu söyler: aynı setlerin en büyük grubu 1 personadır, yani her persona kendi setini alır (önce: 4 / 5). Eval seçimleri de bunu doğrular: P01 PPN/IST/AIS, P02 BVF/NJR/KDE, P03 GBV/YZG/YAY, P04 OKT/RPP/EKF, P05 BVF/GBL/KSK. Önceki tam raporda (`20261012-104535-full`) P01 ile P04 ve P02 ile P05 aynı seçimi almıştı.

Yan etkiler: hakemin "uyarlanmış" puanı %53'ten %57'ye yükseldi (senaryo seti 30'dan 34'e büyüdüğü için bu karşılaştırma yaklaşıktır); kural kontrolleri %100'de kaldı. Karar süresi ortalama 0,86 sn'den 1,16 sn'ye çıktı, çünkü motor artık yalnızca grup başlarından değil tüm sıralı seçeneklerden seçiyor. Kalıcılık için dört regresyon senaryosu eklendi (`reg-d19-p02-diverse`, `reg-d19-p04-diverse`, `reg-d19-p01-unchanged`, `edit-p05-dengeli`) ve yeni kontrol `diverse_recommendations`.

5. Diğer bulgular ve iyileştirmeler

#	Bulgu	Etki	Düzeltme	Sonuç
1	Skor nominaldi; %23 mevduat, %29,73 TÜFE ile vergi sonrası reel −%8,3	Mevduat referansı her fonun üstünde görünüyordu	D9: vergi sonrası reel getiri	P01 referansı 0,912 → 0,568; en iyi fon 0,837
2	809 fonun 189'u TEFAS'ta işlem görmüyor veya kapalı	Her personanın ilk 20'sinde 1–4 alınamaz fon	I3b + D12 `not_buyable`	Listede 0; 189 reddedildi
3	Açık kısıtlar yalnızca cezaydı	P02'de 8 döviz fonu listede kaldı; P05'te valörü 3 günden uzun fonlar	D13: sert kural	P02: listede 0, 14 reddedildi; P05: en çok valör 3
4	TEFAS detay kaynağı ilk canlı çalıştırmada hata verdi (valör zorunlu ama boş)	Kaynak kullanılamadı	Alanlar isteğe bağlı	Kaynak çalışıyor, 5.384 satır

#	Bulgu	Etki	Düzeltme	Sonuç
5	Doğrulayıcı "GARANTİ PORTFÖY" fon adını yasaklı "garanti" ifadesi saydı (N5)	Geçerli metin şablona düştü	Ürün adları taramadan önce çıkarıldı	P01 ifade bulgusu 1 → 0
6	TEFAS detay yokken likidite tahmini tabloya düştü ama güven arttı (D14)	Eksik veri gizleniyordu (0,63 → 0,70)	Tahmin için 0,8 çarpanı	Güven 0,56; eksik veri gösteriliyor
7	İlk tam eval: P05'te VKR, ZPO, ZTV kanıt kimliksiz listelendi (D15)	Kural 2 ihlali; kural kontrolleri %99	Kısa geçmiş kuralı	Kanıtsız seçenek yok; 57 fon `short_history` reddi
E8	Eval, ekranda gösterilen olguların sayılarını tanımıyordu	2 yanlış "uydurma veri" bulgusu; %99	Kontrol ekran olgularını kabul eder	%100; gerçek uydurma sayı hâlâ kalır
N8	İlk tam eval: metin başına $0,136, olgu paketi 35.000–50.000 token	Bütçe riski	Paket yalnızca metnin ihtiyacını taşır	Sonraki tam eval $0,041; son $0,052
N7	Hakem gerekçeleri: metin genel, iç değerler (bayrak adları, skorlar) metinde	Müşteriye uyarlanmamış metin	Her öneri bir müşteri ihtiyacına bağlanır; iç değer yasak	Doğrulayıcıda yeni kurallar; hakem puanı belirgin değişmedi
N9b	Bölüm başına şema (8 kopya) yapılandırılmış çıktı için çok büyük (HTTP 400 "compiled grammar is too large")	Metin üretilemiyordu	Tüm bölümler için tek cümle şeması	Test şemayı küçük tutar; 25 / 25 LLM metni
N9c	Piyasa ortalaması (%43,82) ile ING oranı (%23) pakette aynı adı taşıyordu	Piyasa oranı ING ürün adının yanına yazılabilirdi	Adlandırılmış olgular + etiket kuralı	ING adı olan cümlede yalnızca ING oranı
N10	Panodaki özet canlı denemede 389 karakter (sınır 280)	Özet şablona düşüyordu	Sınır istemde kelimeyle (≈40); sığan tam cümleler tutulur	Kesik cümle yok; aşım doğrulayıcıda kalır

Değerlendirmenin kendi hatası: eski metin önbelleği (2026-10-12)

D19 sonrasında değerlendirme, görüşme metni için hâlâ eski kuralla (grup başları) seçim yapıyordu; ekranda RM'e önerilen ilk 3 ise motorun yeni `recommended` listesiydi. Seçim kuralı düzeltilip paket yeniden çalıştırıldığında **anlatıcı maliyeti 0 $** çıktı: P02–P05 için seçim değiştiği hâlde hiçbir yeni metin üretilmemişti. Neden: metin önbelleğinin anahtarı yalnızca çalıştırma kimliği, dil, istem sürümü ve modeldi; RM seçimi ve notları anahtarda yoktu, bu yüzden aynı çalıştırma için eski seçimin metni döndü ve kontroller eski metni değerlendirdi. Aynı sorun uygulamada da olabilirdi: bir çalıştırma başka bir seçimle yeniden onaylanırsa eski metin veya eski blok düzenlemeleri görünebilirdi.

İyileştirme: (1) değerlendirme artık panodaki öneriyi seçiyor; (2) önbellek anahtarına modelin gördüğü olgu paketinin özeti (sha256, 10 karakter) eklendi (N12) — seçim, onay notu veya seçenek notu değişince yeni metin üretiliyor; (3) bir çalıştırmanın yeni onayı, önceki onaylı metni, blok düzenlemelerini ve bekleyen taslakları siliyor. Her biri testle korunuyor. Sonraki geçerli çalıştırma (`20261012-201431-full`) 25 yeni metin üretti (1,04 $) ve tüm hedefleri karşıladı. Öğrenim: maliyet ve süre gibi "beklenmedik derecede iyi" ölçümler de bir hatanın işareti olabilir.

6. Öğrenimler

1. **Geçmiş getiri tek başına baskın olur.** Bir yıllık veri, piyasa koşulunu herkese uygular. Müşteri profili (risk bandı, varlık sınıfı) ayrı bir sinyal olmalı.
2. **Kesin kurallar cezalardan güvenilirdir.** Kısıtlar (D13) ve çeşitlilik (D19) ceza olarak kaldığında yüksek skor onları aştı. Sert filtre ve seçim kuralı sonucu öngörülebilir ve test edilebilir yaptı.
3. **"Kurallar %100" yeterli değil.** Vaka 8 tüm kontroller yeşilken oluştu. Çıktılar arası karşılaştırma (aynı ilk üç) ve insan incelemesi gerekti.
4. **LLM doğrulayıcısı değerli ama kendisi de test edilmeli.** Uydurma sayı ve yasaklı ifade kaçmadı; ancak N5 ve E8 iki yanlış alarm üretti. Doğrulayıcıya da regresyon senaryosu yazdık.
5. **Yapılandırılmış çıktının boyut sınırı var.** Şemayı küçük tutmak (N9b) ve olgu paketini küçültmek (N8) hem hatayı hem maliyeti düşürdü. Dondurulmuş veri sayesinde her değişikliğin etkisi önce / sonra ölçüldü.

7. Sınırlar

- **Dondurulmuş anlık görüntü:** sonuçlar 2026-10-10 verisine aittir; başka bir piyasa döneminde sıralama farklı olabilir.
- **RM hazırlık süresi ölçülmedi:** sistem süresini ölçtük (kanıt + karar ort. ≈ 1,8 sn, görüşme metni medyan ≈ 30 sn); RM'in bugünkü hazırlık süresi ve kazanç **[VARSAYIM]**, mentorların cevabına kadar.
- **Hakem bir LLM:** puanlar yön göstergesidir; "RM için açık" ve "dengeli" her metinde "kısmen" çıktı. İkinci bir hakemle uyum kontrolü sonraya kaldı.
- **Risk bantları ve D19 ayarları** tek anlık görüntüde ayarlandı; **[VARSAYIM]**, mentorlarla teyit edilecek.
- **Personalar sentetik:** gerçek müşteri verisiyle test yapılmadı.