Test ve öğrenimler

> Teslimat 5 · 2026-10-28 · Kaynaklar: README bölüm 7 (takım onaylı) ve `docs/found-and-fixed.md` (tüm düzeltme kaydı). Sayılar: son tam değerlendirme `data/eval/20261017-160939-n12-client-page` (dondurulmuş snapshot `20261014-233110-1565`, karar yapılandırması `dda3ae095519`, anlatıcı `claude-sonnet-5-5` istem `n12`, hakem `claude-haiku-5-5`); ajan değerlendirmesi `data/eval/20261015-182316-20261015-agent` (P03 yeniden çalıştırması `20261015-183949-20261015-agent-p03`, RM işaretleri `20261015-235705-20261015-marks`); 2 senaryoluk yeniden kontrol `data/eval/20261017-170013-garanti-fix` (bölüm 5.6). **[VARSAYIM]** ile işaretli değerler ölçülmedi.

1. Test yaklaşımı

Çözümü dört açıdan test ettik. Her açı farklı bir soruya cevap verir.

Açı	Ne test eder	Kapsam
Birim ve sözleşme testleri	Her kural tek başına doğru çalışıyor mu? (veri alma, karar motoru, anlatıcı doğrulayıcısı, ajan, API)	`pytest`: 151 dosyada **3.082** test; web: 51 dosyada **458** test (2026-10-28); ağ erişimi yok, dil modeli yerine sahte model
Senaryo değerlendirmesi	Sistem uçtan uca, jürinin değiştirebileceği girdilerle doğru çalışıyor mu?	34 senaryo, 39 çalıştırma; dondurulmuş snapshot; tek komut `python -m rmprep eval`
Ajan değerlendirmesi	Ajan kurallara uyuyor mu, motordan daha iyi mi?	8 karar: kod denetimi, yedeğe düşme oranı, tekrar, kör A/B hakemi, RM işaretleri (`rmprep eval --agent`)
Canlı kontrol ve geri bildirim	Sistem RM için gerçekten kullanışlı mı?	Ekran incelemesi, ücretli canlı kontroller (ör. profil çelişkileri, istem n11/n12), RM işlem kaydından geri bildirim raporu (`rmprep feedback`)

Senaryo değerlendirmesi her senaryoyu gerçek arka uçtan geçirir: karar, panoda RM'e önerilen ilk 3'ün onayı, görüşme metni. Kontroller üç türdür:

1. **Deterministik kurallar (kod):** kısıt uyumu, risk tavanı, alıma kapalı fon, kaynak atfı, uydurma veri, tekrar tutarlılığı ve diğerleri (15 kontrol). Hedef %100.
2. **Dil modeli metninin doğrulayıcısı (kod):** metindeki her sayı olgu paketinde mi, yalnızca izinli ürünler mi adlandırılıyor, yasak ifade var mı, her cümle kanıt kimliği gösteriyor mu. Bir bulgu varsa model bir kez daha dener; yine bulgu varsa metin düz şablona düşer.
3. **LLM hakemi (Claude Haiku 5.5):** yalnızca kodun ölçemediği şeyler: metin bu müşteriye mi uyarlanmış, RM için açık mı, dengeli mi. Kural kontrolleri hakeme bırakılmaz.

Veri dondurulduğu için bir sonuç değişirse kod veya yapılandırma değişmiştir. Metinler önbellekte tutulur; aynı girdi aynı metni verir. Bu önbelleğin bir yan etkisi de vardır (bölüm 5.6).

Senaryo grupları

Grup	Sayı	Neyi değiştirir	Örnek
Temel	5 (her biri 2 kez)	Hiçbir şey; P01–P05 olduğu gibi	`base-p01` … `base-p05`
Hatalı / çelişkili veri	3	Kanıta hata enjekte eder	kaynaklar arası çelişen risk değeri, aralık dışı risk, eskimiş getiri
Persona değişikliği (Jüri Challenge tarzı)	5	Bir müşteri alanını değiştirir	P03 "Agresif" → "Muhafazakâr"; P03 vade "1 yıl"; P04 likidite "Yüksek"; P01 bilinmeyen döviz tercihi metni; P05 "Dengeli"
Kısıt	4	Açık kısıt ekler	"döviz maruziyeti istemiyor", "yüksek riskli ürün istemiyor"; bilinmeyen kısıt metni → RM'e soru
Veri erişimi	4	Bir kaynağı dışlar	TEFAS detay yok; elle girilen veri yok (mevduat oranı, TÜFE, stopaj); TEFAS web yok
Regresyon	13	Geçmiş hataları sabitler	bölüm 5 ve 6'daki vakalar
Ajan (yalnızca `--agent`)	3 + 5 temel	Ajanın davranışını zorlar	motorun 1. fonu için olumsuz haber (P01); RM'in girdiği dağılım (P03); çöken bir hisseyi izleme (P03)

Örnek: TEFAS web dışlanınca P01'de 6 seçenek kalır; önerilenler e-Vadeli mevduat ve bir borsa yatırım fonudur (BTL). Bilinmeyen kısıtta sonuç `needs_rm_input` olur ve motor hiçbir şeyi sıralamaz.

2. Neden bu başarı göstergeleri?

Brif tek bir zorunlu metrik vermez (§9.1). Göstergeleri brifin §9.1'deki boyutlarından ve kesin kurallarından türettik. İlke basittir: brifin kesin kurallarında (kısıt, uydurma veri, kaynak, yasak ifade) hedef %100'dür, tek bir ihlali bile kabul etmiyoruz. Metin kalitesini yalnızca yön göstergesi olarak okuyoruz, çünkü metni puanlayan hakem de bir dil modelidir ve notu kod kontrolleri kadar güvenilir değildir.

Brif boyutu (§9.1)	Göstergemiz	Neden bu gösterge
Müşteri kısıtlarına uyum	Kural 5 kontrolü; risk tavanı; açık kısıtlar sert kural (D13); alıma kapalı fon yok (D12)	Tek bir ihlal RM'in güvenini bozar; kısıt bir ceza değil, bir filtre olmalı
Eksik / çelişkili veri	Eksik veri gösteriliyor; hatalı veri işaretleniyor ve kullanılmıyor; tahmin yerine soru	SPK yerindelik kuralı eksik bilgiyle tavsiyeye izin vermez
Kaynak kullanımının doğruluğu	Her seçenek ve her cümle kanıt kimliği gösteriyor (kural 2); uydurma sayı yok (kural 3); doğrulayıcı geçme oranı	Dil modeli metninin en büyük riski uydurma sayıdır
Tekrar eden çalışmalarda tutarlılık	Aynı girdi → aynı `run_id`, aynı sonuç, aynı metin; ajan için önbelleksiz tekrar	RM ve denetçi aynı sonucu yeniden üretebilmeli
Önerilerin tutarlılığı	Persona değişikliği sonucu beklenen yönde değiştiriyor; çeşitli öneri (D19); hakemin "uyarlanmış" notu	Herkese aynı ürünü öneren bir araç RM'e bir şey katmaz (bölüm 5.1)
İşlem süresi	Kanıt, karar ve metin süresi (saniye; yalnızca rapor)	Araç RM'in görüşme hazırlığına sığmalı
RM hazırlık sürecine katkı	Geri bildirim raporu: RM'in sildiği bölümler, ajan önerisinin kabul payı, dağılım tahmininin hatası	Gerçek RM kullanımı olmadan katkıyı ancak RM işlemlerinden ölçebiliriz; RM'in bugünkü hazırlık süresi **[VARSAYIM]**

Brif boyutu (§9.1)	Göstergemiz	Neden bu gösterge
Maliyet	Paket başına ve yeni metin başına USD	Değerlendirmenin kendi sınırı 5 $ / paket

3. Sonuçlar (son tam değerlendirme)

`data/eval/20261017-160939-n12-client-page`, snapshot `20261014-233110-1565`, istem n12:

Gösterge	Sonuç	Hedef
Kural kontrolleri (15 kontrol)	%100	%100
Kısıt ihlali (kural 5) · risk tavanı aşımı	0 (37/37) · 0 (37/37)	0
Uydurma veri yok · kaynak atfı	39/39 · 39/39	%100
Tahmin yerine soru · eksik veri gösteriliyor	2/2 · 7/7	%100
Persona değişikliği sonucu beklenen yönde değiştiriyor	21/21	%100
Doğrulayıcı (dil modeli metni, şablona düşmeden)	24/25 (%96)	≥ %95
Yasak ifade	0	0
Tekrar tutarlılığı	5/5	%100
Süre: karar · görüşme metni	1,18 sn · 24,9 sn (ortalama)	rapor
Değerlendirme maliyeti	tam paket 0,866 $ · yeni görüşme metni başına 0,034 $	≤ 5 $
LLM hakemi: uyarlanmış / açık / dengeli	%50 / %50 / %58	yön göstergesi

Aynı rapordaki diğer kural kontrolleri de %100 geçti: alıma kapalı fon yok (D12) 37/37, açık kısıtlar sert kural (D13) 12/12, çeşitli öneri (D19) 20/20, hatalı veri işaretleniyor 3/3, mevcut dağılım toplamı doğru (D27) 37/37. Kanıt toplama ortalama 0,95 sn sürdü (en çok 16,00 sn); karar en çok 2,54 sn, görüşme metni en çok 54,13 sn sürdü.

Kısıt ihlali satırında 39 değil 37 çalıştırma var, çünkü iki çalıştırmada motor sıralamayı durdurup RM'e soru sordu ve ortada bir öneri listesi yoktu. Bir kontrol yalnızca ilgili senaryoda çalışır; uygulanmayanlar oranlara girmez. Hakem her soruya "evet" (1), "kısmen" (0,5) veya "hayır" (0) der; tabloda bu notların ortalaması yazar. Uyarlanmış ve açık için %50, hakemin 19 metnin hepsine "kısmen" dediği anlamına gelir; hakem hiçbir metne "hayır" demedi.

Tek kalan hata, 25 metinden birinin şablona düşmesidir (`bad-p04-risk-out-of-range`). Neden yanlış bir alarmdı; düzeltme ve düzeltmenin nasıl ölçülmediği bölüm 5.6'dadır.

4. Ajan motordan daha iyi mi?

Ajan değerlendirmesinde (`20261015-182316`, 8 karar; ajan `claude-sonnet-5-5`, istem a2, 10 aday) ajanın tüm kararları (8/8) kod denetiminden geçti ve hiçbir kararda yedek karara (fallback) düşülmedi. Sistem ajanın kararlarını kaydeder; aynı istek tekrar gelince model yeniden çağrılmaz ve kayıtlı karar döner. Bu yüzden aynı istekler aynı kararı verdi (8/8). Bu bir tutarlılık kanıtı değildir.

Asıl tutarlılık testinde önbelleği boşaltıp aynı girdiyle modeli yeniden çağırdık. 8 kararın 5'inde ilk 3 aynı kaldı; diğer 3'ünde yalnızca bir ürün değişti (24 önerinin 21'i korundu). Ajan bir karar için ortalama 28,92 sn kullandı (en çok 53,83 sn). Davranış senaryoları beklendiği gibi geçti: motorun 1. fonu PPN için olumsuz haber enjekte edilince ajan PPN'yi listeden çıkardı; çöken KTLEV hissesi ne motorun ne ajanın ilk 3'üne girdi.

Ajanın önerisini motorunkiyle kıyaslamak için kör bir A/B hakemi kullandık (Claude Haiku 5.5, rastgele sıra, soru: "Hangisi müşteriye daha uygun ve neden?"). Hakem sistemi bilmez; yalnızca iki seti ve olgularını görür.

Tur	Ajan	Motor	Eşit	Not
İlk tur (`20261015-182316`)	5	0	1	2 kararda ilk 3 aynıydı, soru sorulmadı
P03 yeniden (`20261015-183949` , aday listesi düzeltildikten sonra)	0	2	0	`agent-rm-split` 'te ilk 3 aynı kaldı; iki "motor" yanıtı aynı sorunun yanıtıdır (aşağıda)
RM işaretleri (`20261015-235705`)	1	0	0	✗ işaretli bulgu pakette yok, ✓ işaretli bulgu "RM doğruladı"
Adil karşılaştırmalar, farklı 5 soru	**3**	**1**	**1**	ajan: P01, olumsuz haber, RM işaretleri; motor: P03

İkinci hakem (E13, 2026-10-29). Aynı soruları farklı bir firmanın modeline, Gemini 3.8 Flash'a da sorduk (`rmprep eval-ab-replay` , `data/eval/20261029-150826-ab-replay`). Komut soruları kayıtlı verilerden (müşteri profili, ajanın gördüğü veri paketi, aynı rastgele sıra) yeniden kurar ve yalnızca ilk hakemin gördüğü metinle birebir aynı olan soruları gönderir; bunu ilk hakemin kayıtlı yanıtı kanıtlar. Ajan ve araştırma yeniden çağrılmaz.

Hakem	Ajan	Motor	Eşit
Claude Haiku 5.5	3	1	1
Gemini 3.8 Flash	4	1	0

İki hakem 5 sorunun 4'ünde aynı kazananı seçti. Fark P05'tedir: Haiku "eşit", Gemini ajan dedi ("Set A ... higher nominal and real returns"). Gemini'nin gerekçeleri müşteri olgularına dayanır: P01'de nakit ağırlıklı dağılım, olumsuz haber senaryosunda enjekte edilen SPK haberi, P03'te KDE'nin negatif reel getirisi.

Tekrarın bulduğu sayım hatası. P03'ün yeniden çalıştırmasında `base-p03` ve `agent-crash` hakeme aynı soruyu sordu: aynı profil, aynı veri paketi, aynı çalıştırma kimliği. Hakem bir kez yanıtladı (önbellek), biz ise toplamda bu yanıtı iki kez saydık ve README'ye "ajan 3, motor 2, eşit 1" yazdık. Farklı sorular üzerinden doğru toplam ajan 3, motor 1, eşit 1'dir (`docs/found-and-fixed.md` #21).

İlk turda ajanın 5 kazancının 3'ü P03 senaryolarındaydı ve orada motorun seçtiği IDY ile OKT ajanın aday listesinde yoktu. Hakem bu iki fonun verisini göremiyordu; gerekçesi "Set B's two funds lack data" idi. Bu hata ve düzeltmesi bölüm 5.6'dadır. Düzeltmeden sonra hakem P03'te motoru seçti.

Sonuç. Bu sayılar ajanın motordan daha iyi olduğunu göstermez: örnek küçüktür ve hakem de bir dil modelidir. Bu yüzden RM önce puanlama motorunun önerilerini görür; isterse ajan araştırmasını ve ajanın önerisini sonradan başlatır. RM iki listeyi de görür ve kararı kendisi verir.

5. Hata analizleri

Geliştirme boyunca bulduğumuz her hatayı ve her yanlış varsayımı, nedenini, nedeni nasıl bulduğumuzu, düzeltmeyi ve ölçülen sonucu kaydettik (tam liste: `docs/found-and-fixed.md`). Bu bölüm en öğretici vakaları anlatır.

5.1 Herkese aynı öneri (vaka 8, karar D19)

Ne gördük (2026-10-12). Dondurulmuş snapshot'ta 5 personanın 4'ü ilk üç öneri olarak yalnızca nakit benzeri, SPK risk 1 fonlar aldı. İki çift tamamen aynı listeyi aldı (P01 = P04: Nurol Para Piyasası, İstanbul KV Borçlanma, Ak Para Piyasası Katılım; P02 = P05: One Portföy Para Piyasası ile aynı iki fon); İstanbul KV Borçlanma ve Ak Para Piyasası Katılım dördünde de vardı. Bu grupta Muhafazakâr P01'in yanında Dengeli P02 ve P04 ile Temkinli P05 de vardı. Tüm kural kontrolleri bu sırada %100 geçiyordu: hiçbir kısıt ihlal edilmemişti, ama öneri müşteriye uyarlanmamıştı. Bu vaka "kurallara uyum" ile "iyi öneri" arasındaki farkı gösterdi.

Nedeni nasıl bulduk. Değerlendirme paketinin çıktılarını personalar arasında karşılaştırdık ve skorun bileşenlerini fon fon okuduk:

1. **Geçmiş getiri baskındı.** Son bir yılda TL nakit benzeri fonlar en iyi reel getiriyi verdi (TÜFE ve stopaj sonrası +%7–9); dengeli fonlar +%3, hisse ≈ %0, altın −%13.
2. **Risk bütçesini kullanan bir ölçüt yoktu.** `low_risk` ölçütü Dengeli müşteride de düşük riski ödüllendiriyordu; anapara cezası risk 5 fonları ayrıca vuruyordu (P04: risk 5 karma fon 0,02 puan, para piyasası 0,91).
3. **Çeşitlilik yanlış düzeyde ölçülüyordu.** Çeşitlilik `fund_kind` üzerinden çalışıyordu; para piyasası, kısa vadeli borçlanma ve katılım para piyasası farklı tür ama aynı varlık sınıfıdır (kısa vadeli TL nakit).

Eksik SPK risk değerleri neden değildi (her türde fonların %3–10'u).

Düzeltme (D19, kullanıcı onayı 2026-10-12).

Değişiklik	İçerik
Varlık sınıfı	Her seçeneğe `asset_class`: `nakit_benzeri`, `borclanma`, `dengeli`, `hisse`, `altin_doviz` (tür ve ad kurallarıyla; D23'ten sonra çok varlıklı fonlarda TEFAS portföy dağılımıyla)
Risk uyumu bandı	`low_risk` yerine `risk_fit`: Muhafazakâr [1, 2], Temkinli [2, 3], Dengeli [3, 5], Agresif [4, 7]; bandın altındaki her seviye için ceza
Sınıf kuralı	Dengeli / Agresif müşteride veya çeşitlendirme önceliğinde: sınıf başına en çok 1, en çok 1 nakit benzeri öneri
Reel getiri tabanı (D19b)	Sınıf kuralı negatif 1 yıllık reel getirili bir fonu öne çıkaramaz

İlk denemede `per_step` 0,25 idi; Dengeli personaların önerileri risk 2'de kaldı. `per_step` 0,5 ve `risk_fit` ağırlığı 2,0 ile öneriler bandın içine girdi. Bantlar bir **[VARSAYIM]**; mentorlarla teyit edilecek.

Ölçülen sonuç. D19 anındaki ölçüm (snapshot `20261010-183835-6813`; sınıf, SPK risk değeri r, 1 yıllık reel getiri %) ve son tam değerlendirmenin önerdiği ilk 3:

Persona	D19 öncesi	D19 anında	Son tam değerlendirme (n12)
P01 Muhafazakâr	3 nakit benzeri, risk 1	değişmedi (sınıf kuralı uygulanmaz; doğru davranış)	PPN · OSD · AIS
P02 Dengeli	aynı 3 nakit benzeri, risk 1	nakit r2 +8,0 · borçlanma r2 +8,4 · dengeli r3 +12,8	EIL · KDE · NJR
P04 Dengeli	aynı 3 nakit benzeri, risk 1	borçlanma r3 +5,9 · nakit r2 +6,7 · dengeli r3 +3,3	RPP · OKT · TCF
P05 Temkinli	aynı 3 nakit benzeri, risk 1	3 nakit benzeri, risk 2 (kendi bandı)	EIL · GBL · KSK
P03 Agresif	farklı	dengeli r6 · hisse r7 · katılım r5 +26,3	ASELS (pay) · IDY · OKT

D19'dan sonra **hiçbir iki temel persona aynı ilk üçü paylaşmıyor**. Raporun satırı "1 of 5 base personas share the most common recommended top 3" şunu söyler: aynı setlerin en büyük grubu 1 personadır (önce: 4 personada yalnızca nakit benzeri fonlar). Bazı fonlar birden çok personada yer alır (EIL P02 ve P05'te, OKT P03 ve P04'te), ama hiçbir set aynı değildir. Kalıcılık için dört regresyon senaryosu (`reg-d19-p02-diverse`, `reg-d19-p04-diverse`, `reg-d19-p01-unchanged`, `edit-p05-dengeli`) ve yeni kontrol `diverse_recommendations` eklendi; son tam değerlendirmede bu kontrol 20/20 geçti.

5.2 Profil kendisiyle çelişiyordu ve hiçbir şey bunu göstermiyordu (W42–W44)

Ne gördük (2026-10-17). Bir müşteri profili kendisiyle çelişebilir: "Muhafazakâr" risk profili ile büyüme önceliği; `durum` alanında "gelecek yıl ev peşinatı" ile likidite ihtiyacı "Düşük"; RM notunda "45 yaşında" ile `yas` 62. Yüklenen bir dosya motorun okuyamadığı değerler de taşıyabilir. Hiçbir şey bunu işaretlemiyordu ve RM'in bu konuda ne yaptığı kaydedilmiyordu.

Nedeni nasıl bulduk. Beş personaya bilerek çelişki yerleştirip canlı kontrol yaptık. Motor yalnızca sabit değerleri okuyordu (risk seviyesi, likidite seviyesi, eşleşen öncelikler); serbest metin ve bilinmeyen değerler sessizce geçiyordu. "Teyit edin" onay kutuları da yalnızca tarayıcıda duruyordu.

Düzeltme: üç katman.

Katman	İçerik
Sabit kurallar (W42)	Motorun kendi okuması üzerinde kurallar: risk ile büyüme önceliği, Agresif ile anapara koruma, likidite seviyesi ile likidite öncelikleri, döviz "Açık" ile döviz sınırı (çelişki); 5+ yıl vade ile yüksek likidite ihtiyacı (sorulacak)
AI kontrolü (W43)	Tüm profilin tek bir Claude Opus 5.5 kontrolü. Her bulgu iki tarafı kelimesi kelimesine alıntılamalı; **sunucu bir bulguyu yalnızca her alıntı adı verilen alanda varsa tutar.** Profil başına ≈ 0,015 $, önbellekli
RM gerekçesi (W44)	Bir çelişki, onaydan önce RM'in kısa bir gerekçesini ister ("Müşteriyle teyit edildi: ..."); gerekçe çalıştırmayla, RM işlem kaydında ve kartta tutulur. Bitmemiş bir AI kontrolü onayı engellemez

Ölçülen sonuç (canlı kontrol, 7 profil, 0,10 $, profil başına 2–13 sn).

Ölçü	Sabit kurallar	AI kontrolü
Yerleştirilmiş 5 çelişkiden bulunan	0 / 5	5 / 5
Atılan alıntı (alanında olmayan)	—	0

Ölçü	Sabit kurallar	AI kontrolü
P01, P03, P05'te yanlış alarm	0	0

AI kontrolü P02 ve P04'te iki gerçek nokta da buldu: motor P02'nin döviz metnini okuyamamış ve güvenli seviye "Sınırlı"yı kullanmıştı; P04'ün "kuşaklar arası planlama" önceliğinin sıralamaya hiçbir etkisi yoktu. İkisi de "sorulacak" türündedir ve onayı engellemez.

Öğrenim: sabit kurallar yalnızca motorun okuduğunu görür. Serbest metni bir dil modeli okuyabilir; ama modelin her bulgusunu kod doğrulamalıdır (burada: alıntılar). Bu örnek küçüktür (tek canlı deneme, 5 yerleştirilmiş çelişki).

5.3 İlk sayfa ~33 sn, her müşteri geçişi ~6 sn sürüyordu (hız)

Ne gördük (2026-10-17). Uygulamada ilk sayfa yaklaşık 33 sn, her müşteri geçişi yaklaşık 6 sn sürüyordu.

Nedeni nasıl bulduk. Her adımı yeni bir süreçte zamanladık, sonra cProfile ile profilledik. Üç ayrı neden çıktı; hiçbiri tahmin ettiğimiz yerde değildi:

1. Claude web araması **yedeği**, sunucu açılışında Anthropic SDK'sını yüklüyordu (9,6 sn).
2. Motorun `EvidenceIndex.quantities_of` sorgusu, 1.442 çağrının her birinde yaklaşık 30.000 satırı tarıyordu (profilleyicide 13,3 sn'nin 10,9 sn'si).
3. En yeni snapshot (32.662 satır) ilk istekte okunuyordu (18 sn).

Düzeltme. (1) SDK ilk kullanımda yüklenir (ajan ve araştırma istemcileri). (2) Varlığa göre bir dizin bir kez kurulur. Aynı satırlar, aynı sıra: 276 varlık karşılaştırıldı, 0 fark; ilk 3 aynı kaldı. (3) Sunucu açılışta snapshot'ı ve SDK'yı arka planda yükler; bir kilit, ikinci bir okuma yerine isteği bu okumayı beklemeye alır.

Ölçülen sonuç.

Ölçü	Önce	Sonra
Sunucu açılışı	8,7 sn	2,3 sn
Motor, müşteri başına	6,2 sn	1,4 sn
Değerlendirmede karar, çalıştırma başına (aynı 34 senaryo)	2,86 sn (15.10, `20261015-013525-20261015-final`)	1,18 sn (17.10, n12)
Önerilen ilk 3	—	değişmedi

Not: değerlendirmedeki karar süresi çalıştırmadan çalıştırmaya oynar. Aynı 34 senaryonun 14–15.10'daki iki tam çalıştırması 1,67 sn ve 1,94 sn verdi. Bu yüzden asıl ölçü, geliştirme sırasındaki adım zamanlamasıdır (6,2 → 1,4 sn).

5.4 Pay fiyat geçmişinde ani düşüşler (bölünme düzeltmesi, I11b–I11e)

Ne gördük (2026-10-14). BIST pay geçmişinde ani sıçramalar vardı; KORDS'un 1 aylık getirisi −%96 görünüyordu.

Nedeni nasıl bulduk. Bilinen şirket işlemlerinin (bölünme, bedelsiz) çevresindeki fiyatlara baktık. Bültendeki "önceki kapanış" sütunu (`ONCEKI KAPANIS FIYATI`) bölünmeye göre düzeltilmemişti ve `REFERANS FIYAT` 0'dı. Bu yüzden düzeltme kuralımız hiç çalışmamıştı.

Düzeltme. Günlük fiyat limiti ±%10'dur. Bir kapanışın önceki kapanışa oranı ±%10,5'in dışındaysa bunu şirket işlemi sayarız ve önceki tüm kapanışları o oranla düzeltiriz (I11b). O günün taban fiyatını günlük limitle uyumlu bir aralığa sıkıştırırız (I11c). Nakit temettüler limitin altında kalır ve düzeltilmez; getiriler fiyat getirisidir. Açılış fiyatının taban fiyatı temsil etmesi bir **[VARSAYIM]**'dır.

Ölçülen sonuç (snapshot `20261014-164524-42c2`, 276 bülten dosyası). 111 payda 116 düzeltme. KORDS 1 ay: −%96 → −%27,8. Açılış 116 günün 99'unda aralığın içindeydi, 17 günde sıkıştırıldı; HRKET 1 ay +%93,2 → +%75,9. Bazı paylar düzeltmeden sonra da 1 ayda yaklaşık −%90 gösterir (ANELE, GUNDG, TEHOL): art arda yaklaşık 20 taban günü gerçektir, şirket işlemi değildir.

İlgili bir hata (I11e). 5 yıllık geçmiş 15.02.2023'te kesiliyordu. İlk 5 yıllık veri alımı 8–14.02.2023 bültenlerini "okunamaz" işaretlemişti ("kapanışı olan 0 pay"). Neden: 6 Şubat 2023 depreminden sonra borsa kapalıydı ve bir koruma kuralı boş günleri bozuk dosya sayıyordu. Düzeltme: kapanışı 0 olan geçerli bir bülten = işlem olmayan gün. Sonuç: tam 5 yıllık geçmiş.

5.5 ING'nin kendi oranları eskimişti (I14)

Ne gördük (2026-10-16). ING mevduat oranları 10.10'da elle bir dosyaya kopyalanmıştı. Motor e-Vadeli seçeneği için %35,00 kullanıyordu.

Nedeni nasıl bulduk. ING'nin kamuya açık oran sayfasını (3 adımlı form geri gönderimi) okuduk ve elle girilen dosyayla karşılaştırdık: 28 e-Vadeli oranı değişmişti. Elle girilen bir dosya zamanla eskir.

Düzeltme. ING'nin oran sayfası için bir adaptör ekledik (robots.txt ve kullanım şartları kontrol edildi). Elle girilen dosyalar yedek olarak kalır. Sayfa veya tablo değişirse kaynak hata verir ve önceki iyi snapshot kullanılır; hiçbir zaman yarım satır yazılmaz.

Ölçülen sonuç. Motor, kullandığı hücrede (32–45 gün, 99.999,99–250.000 TL) %35,00 yerine 16.10 sayfasının güncel %34,50'sini kullanır; 7–15 gün hücresi %33,00 → %32,00. Not: değerlendirmenin dondurulmuş snapshot'ı (14.10) bu adaptörden öncedir; değerlendirmedeki ING oranları elle girilen dosyadan gelir.

5.6 Değerlendirmenin kendi hataları

Değerlendirme de bir koddur ve hata yapar. Dört vaka bulduk. Ortak öğrenim: bir ölçüm "beklenmedik derecede iyi" veya "değişmemiş" görünürse önce ölçümün kendisini kontrol et.

(a) A/B hakemi adil olmayan bir karşılaştırma görüyordu (2026-10-15).

- *Ne gördük:* ilk turda A/B hakemi 5 kez ajanı, 0 kez motoru seçti. P03'teki gerekçeleri tuhaftı: "Set B's two funds lack data".
- *Nedeni nasıl bulduk:* hakemin girdilerini okuduk. P03'te D19 sınıf kuralı motorun IDY ve OKT seçimlerini 10. sıranın altından almıştı. Ajan yalnızca ilk 10 adayı görüyordu. Bu yüzden ajan bu iki fonu tutamadı (2 değişiklik zorunluydu) ve hakem onların olgularını göremedi. Ajanın 5 "kazancının" 3'ü adil değildi.
- *Düzeltme:* aday listesi (`candidates()`) artık motorun ilk 3'üyle başlar ve 10'a kadar ekran sırasıyla dolar. Üç P03 senaryosu yeniden çalıştırıldı.
- *Ölçülen sonuç:* yeniden çalıştırmada hakem P03'te motoru seçti. Adil toplam, farklı 5 soru: ajan 3, motor 1, eşit 1 (bölüm 4); ikinci hakem Gemini: ajan 4, motor 1; iki hakem 5 sorunun 4'ünde aynı. Düzeltmeden önceki "%100 ajan" sonucu bir ölçüm hatasıydı.

(b) Eski metin önbelleği (2026-10-12). D19'dan sonra seçim kuralı düzeltilip paket yeniden çalıştırıldığında **anlatıcı maliyeti 0 $** çıktı: P02–P05 için seçim değiştiği hâlde yeni metin üretilmemişti. Metin önbelleğinin anahtarı yalnızca çalıştırma kimliği, dil, istem sürümü ve modeldi; RM seçimi anahtarda yoktu, bu yüzden kontroller eski metni değerlendirdi. Düzeltme (N12): önbellek anahtarına modelin gördüğü olgu paketinin özeti (sha256, 10 karakter) eklendi; bir çalıştırmanın yeni onayı önceki metni ve düzenlemeleri siler. Sonraki çalıştırma (`20261012-201431-full`) 25 yeni metin üretti (1,04 $) ve tüm hedefleri karşıladı.

(c) "Garanti Portföy" yasak ifade sayıldı ve yeniden kontrol bunu ölçmedi (2026-10-17).

- *Ne gördük:* n12 tam değerlendirmesinde 25 metnin 1'i şablona düştü (doğrulayıcı %96). Hata listesi cümleyi ve bulguyu verdi: "Fon sepeti grubunda Osmanlı OLE, Garanti Portföy GZP ve İstanbul IRF bulunur." → yasak ifade "garanti".
- *Neden:* doğrulayıcı yasak ifade taramasından önce fonların tam adlarını ve kısa adlarını çıkarıyordu, ama "ihraççı + fon kodu" biçimini çıkarmıyordu. Kısa n12 metinleri bu biçimi daha sık yazar. (Aynı ailenin ilk vakası N5 idi: "GARANTİ PORTFÖY" tam fon adı.)
- *Düzeltme:* doğrulayıcı adı geçen her fonun ihraççısını ihraççı sözcüğüyle birlikte ("garanti portföy") da çıkarır. Başka bir yerdeki "garanti" hâlâ bir bulgudur. İki yönlü birim testi: `test_the_issuer_with_its_code_passes` ve `test_a_real_garanti_next_to_the_issuer_still_fails`.
- *Yeniden kontrol ne ölçtü:* düzeltmeden sonra 2 senaryoluk bir kontrol çalıştırdık (`20261017-170013-garanti-fix`: `bad-p04-risk-out-of-range` ve `base-p04`, 3 çalıştırma). Rapor doğrulayıcıyı **%67 (2/3)** gösterir ve aynı hatayı aynı cümleyle yeniden listeler. Neden: anlatıcı önbelleği şablona düşen metni de, son denemenin bulgularıyla birlikte kaydeder. Yeniden kontrol üç metni de önbellekten okudu (anlatıcı maliyeti 0,000 $, metin süresi ortalama 0,97 sn). Model çağrılmadı ve yeni doğrulayıcı bu metin üzerinde hiç çalışmadı. Yani bu rapor düzeltmeyi **ölçmedi**; eski sonucu tekrarladı. Kural kontrolleri bu raporda da %100'dür.
- *Ölçüm (2026-10-29, `20261029-153753-garanti-fix-measured`):* önbellekteki şablon metni arşive taşıdık ve senaryoyu ücretli olarak yeniden çalıştırdık (0,088 $). Doğrulayıcı %100 (3/3), 3 metnin üçü de dil modelinden. Ama maliyet defteri ilk denemeyi de gösterdi: model bu kez "Garanti GZP" yazdı (ihraççı "Portföy" sözcüğü olmadan, fon koduyla) ve ilk deneme yine "garanti" bulgusuyla kaldı; metin ancak tekrarda geçti.
- *İkinci düzeltme:* doğrulayıcı "ihraççı + fon kodu" biçimini "Portföy" sözcüğü olmadan da ad sayar ("garanti gzp"). Koddan hemen sonra gelmeyen bir "garanti" hâlâ bulgudur ("Garanti ile AAL getirisi korunur."). Birim testleri: `test_the_short_issuer_with_its_code_passes`, `test_garanti_without_the_code_right_after_still_fails`.
- *Öğrenim:* bir ölçüm ancak eski sonucu tekrar okumadığında ölçümdür; ve ilk deneme bulguları defterde olmasaydı tekrarın gizlediği ikinci biçimi görmezdik.

(d) Piyasa notunda yanlış "uydurma veri" alarmı (vaka 9, 2026-10-14). Snapshot `20261014-233110-1565` ile ilk tam çalıştırmada 25 metnin hepsi kural 3'te kaldı. Neden: kod tarafından yazılan piyasa notu kendi EVDS satırlarını (ör. USD/TRY "49,28") gösteriyordu, ama kontrol yalnızca karar sonucunun satırlarına izin veriyordu. Düzeltme: bir cümle, kendi gösterdiği satırların değerini ve tarihini kullanabilir; aynı sayı kaynak göstermeden yine kalır. Sonuç: %100.

5.7 Metin kalitesi ve hakem (N13, N16)

Ne gördük (2026-10-12). `20261012-201431-full` çalışmasında kural ve doğrulayıcı kontrolleri %100 geçti, ama hakem notları düşüktü (uyarlanmış %57, RM için açık %50, dengeli %50). Hakem gerekçelerini ve

metinleri okuduk. Anlatıcıda doğrulanan nedenler: seçenek başına risk, erişim ve ücret olgusu yoktu (19 metnin 11'inde dikkat bölümünde yalnızca geçmiş getiri cümlesi vardı); nominal getiri reel getiriden önce geliyordu; "geçmiş getiri" uyarısı metin başına yaklaşık 6 kez geçiyordu.

Düzeltme. İstemler n7–n9: olgu paketinde seçenek başına risk satırı, önce reel getiri, uyarı yalnızca dikkat bölümünde; doğrulayıcıya ölçülebilir yeni kurallar (`repeat`: dikkat bölümü öneriyi tekrar etmez; `compare`: ING mevduatı ile piyasa ortalaması yalnızca RM'e özel notta). 2026-10-17'de bir takım üyesi müşteri sayfasını inceledi; bu inceleme istemi bir kez daha değiştirdi (N16, n11–n12: fon başına 1–2 cümle, ortak risk bir kez, fon adı cümlenin başında değil, iki fikir ";" ile birleşmez). Canlı kontrolde 10 metnin hepsi doğrulayıcıdan geçti; teklif metninde 100 karakteri aşan cümle 2/16'dan 0/17'ye indi.

Hakem notlarının seyri.

Değerlendirme	İstem	Kural kontrolleri	Hakem: uyarlanmış / açık / dengeli
`20261012-201431-full`	n6	%100	%57 / %50 / %50
`20261013-004507-full`	n9	%100	%52 / %50 / %60
`20261015-013525-20261015-final`	n10	%100	%55 / %52 / %62
`20261017-160939-n12-client-page`	n12	%100	%50 / %50 / %58

Yorum. Nesnel ölçüler iyileşti, hakem notu ise yerinde kaldı. Hakem katıdır ("kararsızsan düşük olanı seç" kuralı) ve küçük bir modeldir; son çalışmada 57 notun 54'ü "kısmen"dir. Hakemin ölçütü RM notu için yazıldı, müşteri sayfası için değil. Hakem de değişti (j2 → j3, daha çok bağlam); bu yüzden önce / sonra karşılaştırması yaklaşıktır.

Hakem notunu bilerek optimize etmedik. Bir LLM hakemi için istem ayarlamak, metni o hakemin zevkine göre ayarlamak olur; bu, RM için daha iyi bir metin demek değildir. Bunun yerine ölçülebilir kurallar ekledik ve RM incelemesine güvendik. İkinci bir hakemi (Gemini) şimdilik yalnızca A/B karşılaştırmasında kullandık (bölüm 4); metin notları için ikinci hakem sonraki adımdır.

6. Diğer bulgular ve iyileştirmeler

Tümü `docs/found-and-fixed.md`'de veya regresyon senaryosu olarak değerlendirme raporundadır.

#	Ne gördük	Etki	Düzeltme	Ölçülen sonuç
D24	Stopaj ve TÜFE yokken fonun veri güveni 1,00 kalıyordu	Eksik veri gizleniyordu; "eksik veri gösteriliyor" 5/7	Reel getiri hesaplanamazsa güven × 0,8. Eski bir "kontrol gerekli" bayrağı bu açığı gizliyordu ve kontrol yanlış nedenle geçiyordu	5/7 → 7/7 (`20261014-104638-nollm-check` → `20261014-105544-nollm-check2`)
D9	Skor nominaldi; %23 mevduat, %29,73 TÜFE ile vergi sonrası reel −%8,3	Mevduat referansı her fonun üstünde görünüyordu	Vergi sonrası reel getiri	P01 referansı 0,912 → 0,568; en iyi fon 0,837
D12	809 fonun 189'u TEFAS'ta işlem görmüyor veya kapalı	Her personanın ilk 20'sinde 1–4 alınamaz fon	`not_buyable` reddi	Listede 0; 189 reddedildi

#	Ne gördük	Etki	Düzeltme	Ölçülen sonuç
D13	Açık kısıtlar yalnızca cezaydı	P02'de 8 döviz fonu listede kaldı	Sert kural	P02: listede 0, 14 reddedildi; P05: en çok valör 3
D15	P05'te VKR, ZPO, ZTV kanıt kimliksiz listelendi	Kural 2 ihlali	Kısa geçmiş kuralı	Kanıtsız seçenek yok; 57 fon `short_history` reddi
D25	Sınıf kuralının uzak sıradan seçtiği öneriler kararlılık 0,00 aldı (snapshot `20261014-102329-8fca`: P03 IDY sıra 42, OKT sıra 57)	İlk 3'ün kararlılığı anlamlı değildi; `low_stability` uyarısı yalnızca 1–3. sıraya bakıyordu	Kararlılık = 30 bozulmuş çalıştırmada öneri kuralının onu yeniden önerme payı; uyarı tüm önerilere bakar	P03 IDY ve OKT 0,00 → 1,00; P01–P05'in tüm önerileri ≥ 0,83
#1	Araştırma panelinde bir haber maddesi ham JSON ile bitiyordu	Demo kaydında görüldü	Bozuk JSON parçası kesilir; kayıtlı sonuçlar okunurken onarılır	Madde düzgün biter; 3 yeni test
#2	Düzenlenmiş profil onaylanamıyordu, oysa kural buna izin veriyordu	Demo kaydı durdu	Kural API'de kaldırılmıştı ama gerçek arka uçta ve bir testte kalmıştı; ikisi de düzeltildi	Düzenlenmiş P03 onaylanır
#6	Dağılım onayından sonra ajan araştırması "silindi"	RM işi kayboldu	Yeni dağılım yeni bir çalıştırmadır; API ajanı yeni çalıştırmada aynı aday sayısıyla başlatır	Araştırma kaybolmaz; tekrar maliyetsiz (önbellek)
#7	"Kategorileri gör" 20 fon gösterirken adım 141 aday diyordu	Sayılar tutmuyordu	Kategoriler fonun neye yatırım yaptığına göre, tüm puanlı seçenekler üzerinden	Sayılar adım sayısına eşit (P01: 143 = 143)
#11	Diğer bankaların oran bloğu hiç görülmüyordu	Blok, gerçek bir çalıştırmanın hiç açmadığı bir çekmecedeydi (gerçek veride e-Vadeli seçeneği sıra 73–382)	Oranlar her zaman görünen "Piyasa notu"na da girer	Her müşteride görünür; ilk kontrol örnek veriyle yapılmıştı
N8	İlk tam değerlendirmede metin başına 0,136 $	Bütçe riski	Olgu paketi yalnızca metnin ihtiyacını taşır	Son tam değerlendirmede yeni metin başına 0,034 $

7. Öğrenimler

1. **"Kurallar %100" yeterli değildir.** Herkese aynı öneri (5.1) tüm kontroller yeşilken oluştu. Çıktılar arası karşılaştırma ve insan incelemesi gerekti.
2. **Geçmiş getiri tek başına baskın olur.** Bir yıllık veri, piyasa koşulunu herkese uygular. Müşteri profili (risk bandı, varlık sınıfı) ayrı bir sinyal olmalıdır.
3. **Kesin kurallar cezalardan güvenilirdir.** Kısıtlar (D13) ve çeşitlilik (D19) ceza olarak kaldığında yüksek skor onları aştı. Sert filtre ve seçim kuralı sonucu öngörülebilir ve test edilebilir yaptı.
4. **Dil modelinin bulgusunu kod doğrulamalıdır.** Profil kontrolünde (5.2) model serbest metindeki çelişkileri buldu; sunucu her alıntıyı alanında aradı. Ajanın her önerisi de kod denetiminden geçer (8/8).

5. **Önce ölç, sonra düzelt.** Yavaşlığın üç nedeni de tahmin ettiğimiz yerde değildi (5.3); cProfile onları buldu. Düzeltme ilk 3'ü değiştirmedi, çünkü aynı satırları aynı sırayla karşılaştırdık.
6. **Veriyi bilinen olaylarla sına.** Bölünme düzeltmesi (5.4) ve deprem günleri, bilinen şirket işlemlerine ve tarihlere bakınca ortaya çıktı.
7. **Elle girilen veri eskir.** ING oranları (5.5) 10.10 ile 16.10 arasında değişti. Otomatik kaynak birincil, elle girilen dosya yedek olmalıdır.
8. **Bir karşılaştırma ancak iki taraf aynı bilgiyi görürse adildir.** A/B hakemi (5.6 a) motorun fonlarını göremediği için ajanı seçiyordu.
9. **Önbellek bir değişikliği gizleyebilir.** İki kez oldu: 2026-10-12'de eski metin döndü (5.6 b); 2026-10-17'de yeniden kontrol, şablona düşmüş eski metni okudu ve doğrulayıcı düzeltmesini ölçmedi (5.6 c). Maliyet 0 $ ve çok kısa metin süresi bunun işaretiydi.
10. **Bir kural değişikliği her katmanda aranmalıdır.** Düzenlenmiş profil kuralı API'de değişti, gerçek arka uçta ve bir testte eski hâliyle kaldı (bölüm 6, #2).
11. **Bir ekran değişikliğini gerçek veriyle kontrol et.** Diğer bankaların oran bloğu örnek veride görünüyordu, gerçek veride hiç görünmüyordu (bölüm 6, #11).
12. **Bir LLM hakemine göre optimize etmek bir tuzaktır.** Metin nesnel ölçülerde iyileşti, hakem notu yerinde kaldı (5.7). Hakemin zevkine göre ayar yerine ölçülebilir kurallar ekledik.

8. Sınırlar

- **Dondurulmuş snapshot:** değerlendirme sonuçları `20261014-233110-1565` snapshot'ına (2026-10-14 akşamı) aittir; başka bir piyasa döneminde sıralama farklı olabilir. Bu snapshot ING oran adaptöründen (16.10) öncedir.
- **RM hazırlık süresi ölçülmedi:** sistem süresini ölçtük (karar ort. 1,18 sn, görüşme metni ort. 24,9 sn); RM'in bugünkü hazırlık süresi ve kazanç **[VARSAYIM]**.
- **Hakem bir LLM:** notlar yön göstergesidir; son tam değerlendirmede 57 notun 54'ü "kısmen"dir. Metin notları için ikinci bir hakemle uyum kontrolü yapılmadı (A/B için yapıldı: 5 sorunun 4'ünde uyum).
- **Ajan karşılaştırması küçük:** adil A/B karşılaştırmaları farklı 5 sorudur (Haiku: ajan 3, motor 1, eşit 1; Gemini: ajan 4, motor 1); önbelleksiz tekrarda 8 kararın 5'i aynı kaldı.
- **Profil kontrolü tek canlı deneme:** 5 yerleştirilmiş çelişki ve 7 profil; daha geniş bir çelişki seti test edilmedi.
- **Risk bantları ve D19 ayarları** tek snapshot'ta ayarlandı; **[VARSAYIM]**, mentorlarla teyit edilecek.
- **Personalar sentetik:** gerçek müşteri verisiyle test yapılmadı.
- **Geri bildirim raporu gerçek RM kullanımı görmedi:** RM işlem kaydı yalnızca kendi test işlemlerimizi içerir; rapor hiçbir ayarı kendiliğinden değiştirmez. Otomatik değerlendirme döngüsü gelecek iştir.
- **Pay getirileri fiyat getirisidir:** nakit temettüler düzeltilmez.

9. Hâlâ açık konular

- **TEFAS sıfırları:** TEFAS bazı günlerde bir fonun fiyatını ve büyüklüğünü 0 olarak yayımlar (son snapshot'ta 45 fon); bu sıfırları henüz işaretlemiyoruz (I9, planlı).
- **Doğrulanmamış EVDS serileri:** bazı EVDS serileri (BIST 100 getiri endeksi, altın, …) elle doğrulanmadı; bu seriler hâlâ "doğrulanmamış seri" bayrağı taşır.
- **Garanti düzeltmesi:** tek senaryoda ölçüldü (5.6 c); ikinci biçim ("Garanti GZP") birim testiyle korunuyor. Tam paket yeniden çalıştırılmadı; paketin son ölçümü hâlâ %96'dır.

- **Hakemin ölçütü:** hakem (Claude Haiku) neredeyse her metne "kısmen" der ve ölçütü müşteri sayfası için değil, RM notu için yazılmıştır (n10 → n12: uyarlanmış %55 → %50, açık %52 → %50, dengeli %62 → %58; kural kontrolleri %100'de kaldı).
- **İkinci hakem ve RM incelemesi:** yapılmadı; mentorlarla ve gerçek RM'lerle yapılmalıdır.
